

Projektová dokumentace
Implementace překladače imperativního jazyka IFJ23
Tým xdanie14, varianta vv-BVS

5. prosince 2023

Tomáš Daniel	xdanie14	X %
Martin Slezák	xsleza26	X %
Jakub Antonín Štigler	xstigl00	X %
Milan Vrbas	xvrbas01	X %

Obsah

1	Úvod	1
2	Jednotlivé části překladače	1
3	Návrh a implementace	1
3.1	Lexikální analýza	1
3.1.1	Diagram konečného automatu	2
3.2	Syntaktická analýza	3
3.2.1	Rekurzivní sestup	3
3.2.2	Precedenční syntaktická analýza	5
3.3	Sémantická analýza	6
3.3.1	Tabulka symbolů	6
3.4	Generování kódu	6
3.5	Rozšíření	6
4	Práce v týmu	7
4.1	Organizace	7
4.2	Rozdělení práce	7
5	Závěr	7

1 Úvod

Tato dokumentace slouží k popisu implementace a vývoje **překladače pro jazyk IFJ23**, který je podmnožinou jazyka **Swift 5** od společnosti Apple. Program má za úkol načíst kód v tomto jazyku a přeložit ho do cílového jazyka **IFJcode23**. Vybrali jsme si variantu zadání **vv-BVS**, podle které jsme pomocí **výškově vyváženého binárního vyhledávacího stromu** implementovali **tabulku symbolů**.

2 Jednotlivé části překladače

Realizovaný překladač se dá rozdělit na následující dílní moduly:

- **Scanner** - lexikální analyzátor
- **Parser**
 - Syntaktický analyzátor
 - Sémantický analyzátor
- **Codegen** - Genérátor cílového kódu

Samotný překlad nejprve provede lexikální analýzu, následuje syntaktický analyzátor spolu se sémantickou analýzou a poté se přistoupí k generování cílového kódu.

3 Návrh a implementace

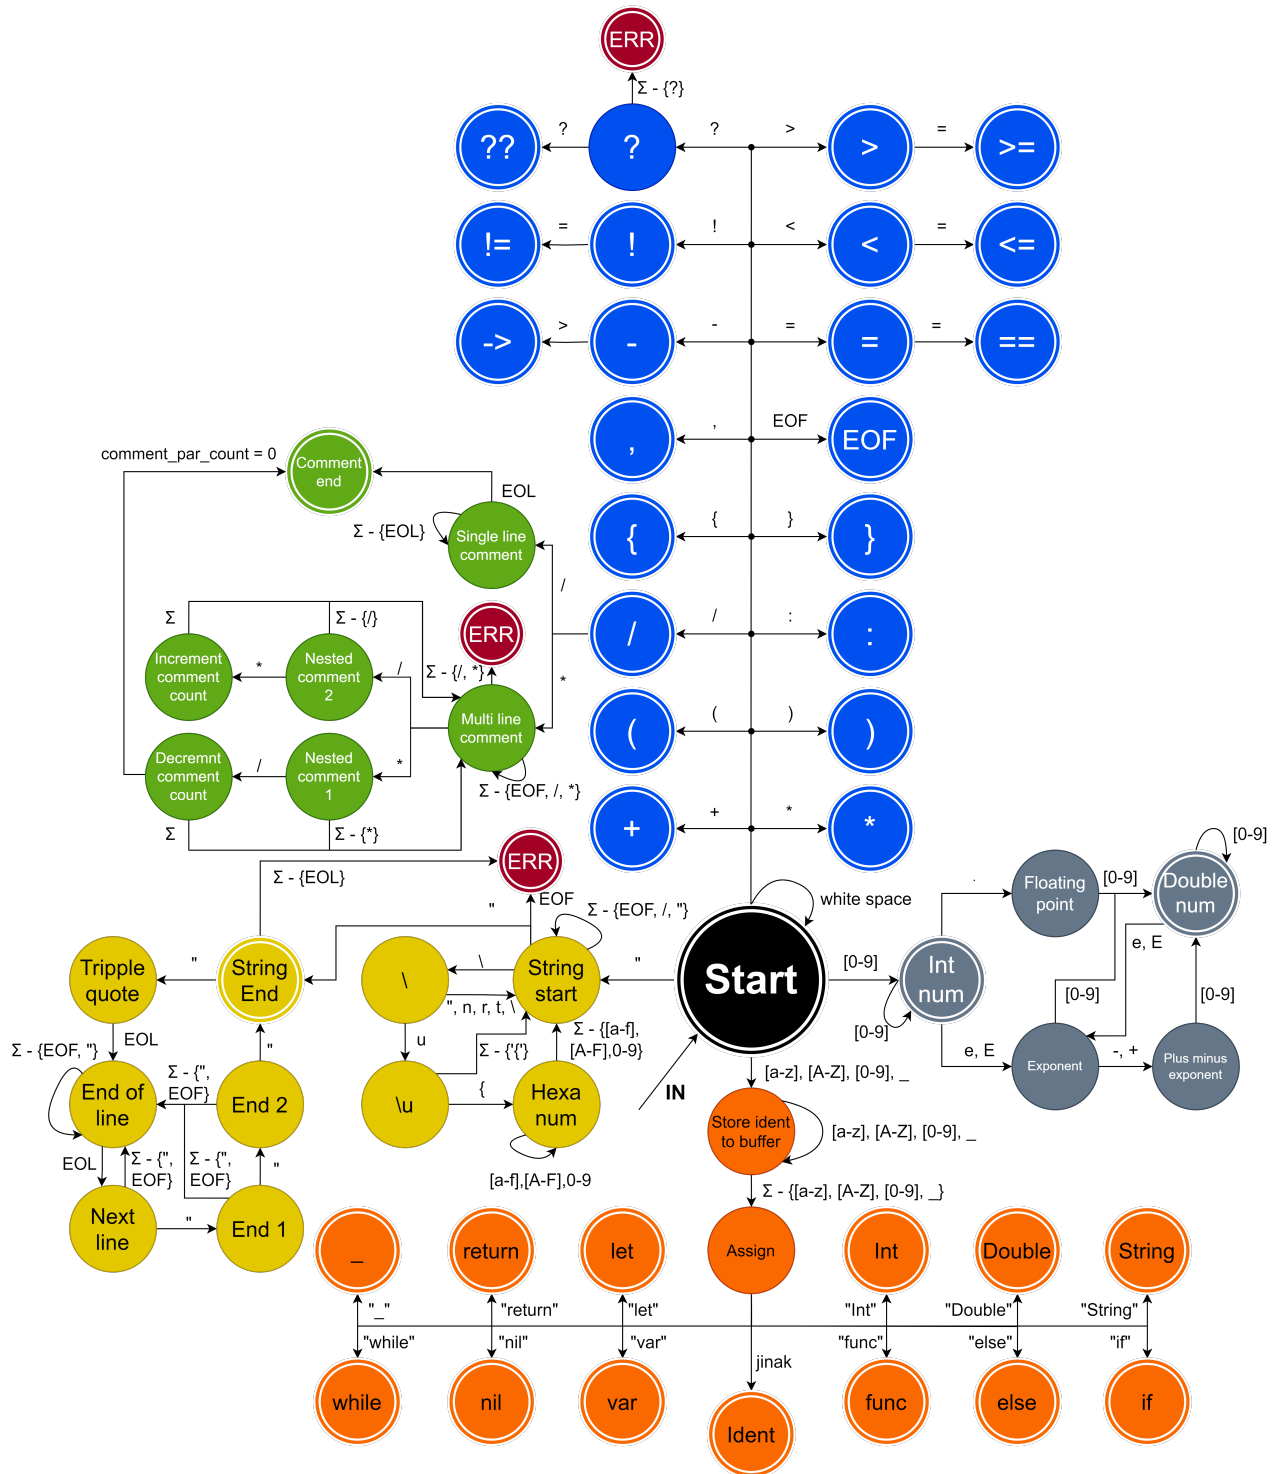
3.1 Lexikální analýza

Jako první část projektu, kterou jsme implementovali byla lexikální analýza, kterou lze najít v modulu *lexer.c*. Ta se stará o načítání znaků neboli lexémů ze standardního vstupu a rozdělování vstupních dat na jednotlivé tokeny, u nichž následně určuje jejich typ a posílá je k syntaktické a sémantické analýze k dalšímu zpracování.

Lexikální analýza využívá koncept **konečného automatu** pro identifikaci a zpracování tokenů ve vstupním kódu. Tento přístup umožňuje systematicky analyzovat postupně načtené znaky a identifikovat je jako jednotlivé tokeny na základě definovaných pravidel a přechodů mezi stavy automatu. Tímto způsobem je struktura vstupního kódu efektivně analyzována a převedena do podoby tokenů pro další zpracování.

Funkce *lex_next()* zajišťuje většinu vnitřní logiky scanneru tím, že načte token a uloží ho do struktury *Lexer*, která obsahuje důležité informace o každém předaném tokenu. V případě, že ve zdrojovém souboru narazí na neplatný token či neplatnou posloupnost znaků, překladač skončí s návratovou hodnotou, která odpovídá konkrétnímu příznaku lexikální chyby.

3.1.1 Diagram konečného automatu



Obrázek 1: Diagram zobrazující konečný automat

Poznámka: pokud automat nemá možnost přejít do dalšího stavu z nekonečného stavu, je to automaticky bráno jako chyba. (pro zjednodušení návrhu automatu)

3.2 Syntaktická analýza

3.2.1 Rekurzivní sestup

Implementace syntaktické analýzy se nachází v souboru **parser.c**, který se zabývá aplikací metody shora dolů, respektive **rekurzivního sestupu**, který je složen z **LL-gramatiky** a **LL-tabulky**. Parser si za svůj vstup bere jednotlivé tokeny z lexikální analýzy a následně nalpni tabulku symbolů v podobě výškově vyváženého binárního vyhledávacího stromu (vv-BVS). Pro většinu neterminálů z LL-gramatiky je sestavena funkce, která následně volá další funkce na základě předcházejícího tokenu. Tyto tokeny se získávají pomocí funkce *lex_next()*.

LL-gramatika

1. MAIN -> "EOF"
2. MAIN -> STATEMENT MAIN
3. MAIN -> "func" ident "(" PARAMS ")" RETVAL "{" STATEMENT "}" MAIN
4. STATEMENT -> ϵ
5. PARAMS -> ϵ
6. PARAMS -> name ident ":" TYPE PARAMS_NEXT
7. TYPE -> "Int" Q_MARK
8. TYPE -> "Double" Q_MARK
9. TYPE -> "String" Q_MARK
10. Q_MARK -> ϵ
11. Q_MARK -> "?"
12. PARAMS_NEXT -> ϵ
13. PARAMS_NEXT -> ", " PARAMS
14. RETVAL -> ϵ
15. RETVAL -> "->" TYPE
16. STATEMENT -> VAR RIGHTSIDE STATEMENT
17. VAR -> "let" ident ":" TYPE
18. VAR -> "var" ident ":" TYPE
19. RIGHTSIDE -> ϵ
20. RIGHTSIDE -> "=" EXPR
21. EXPR -> "Do it using precedence table"
22. STATEMENT -> ident "=" EXPR STATEMENT
23. STATEMENT -> "=" COND "{" STATEMENT "}" ELSESTAT
24. COND -> EXPR
25. COND -> "(" "let" ident ")"
26. COND -> "let" ident
27. ELSESTAT -> STATEMENT
28. ELSESTAT -> "else" "{" STATEMENT "}" STATEMENT
29. WHILESTAT -> "while" COND "{" STATEMENT "}" STATEMENT
30. FUNCCALL -> LEFTSIDE ident "(" FUNCPARAMS ")" STATEMENT
31. LEFTSIDE -> ϵ
32. LEFTSIDE -> VAR "="
33. FUNCPARAMS -> ϵ
34. FUNCPARAMS -> ident ":" name FUNCPARAMS_NEXT
35. FUNCPARAMS -> name FUNCPARAMS_NEXT
36. FUNCPARAMS_NEXT -> ϵ
37. FUNCPARAMS_NEXT -> ", " FUNCPARAMS
38. STATEMENT -> "return" VALUE STATEMENT
39. VALUE -> EXPR

LL-tabulka

	EOF	func	ident	()	{	}	ϵ	name	:	Int	Double	String	?	,	->	let	var	=	"Expression"	if	else	while	return
MAIN	1	3	2					2									2	2			2			2
STATEMENT			22					4									16	16			23			38
PARAMS								5	6															
TYPE											7	8	9											
Q_MARK								10						11										
PARAMS_NEXT								12							13									
RETVL								14								15								
VAR																	17	18						
RIGHTSIDE								19											20					
EXPR																				21				
COND				25													26			24				
ELSESTAT								27														28		
WHILESTAT																							29	
FUNCCALL								30									30	30						
LEFTSIDE								31									32	32						
FUNCPARAMS			34					33	35															
FUNCPARAMS_NEXT								36							37									
VALUE																				39				

Obrázek 2: Tabulka zobrazující LL-tabulku

3.2.2 Precedenční syntaktická analýza

Precedenční syntaktická analýza neboli PSA se stará o syntaktickou analýzu metodou zdola-nahoru pomocí **precedenční tabulky**. Na základě žádosti PSA pošle lexikální analyzátor token, který se poté zpracuje s nejvyšším tokenem na zásobníku a funkce *prec_table* na základě níže uvedených pravidel vrátí to, které se má na daný výraz aplikovat. Precedenční syntaktická analýza končí v moment, kdy přijde prázdné pravidlo a zároveň je zásobník (*stack*) prázdný. Následně skončí úspěšně a vrátí poslední načtený znak. V opačném případě končí neúspěšně.

	π	*	/	+	-	==	!=	<	>	<=	>=	??	=	()	<i>t</i>	\$
π	>	>	>	>	>	>	>	>	>	>	>	>	!	c	>	.	.
*	!	>	>	x	x	>	>	>	>	>	>	>	!	<	>	<	.
/	!	>	>	x	x	>	>	>	>	>	>	>	!	<	>	<	.
+	!	0	0	>	>	>	>	>	>	>	>	>	!	<	>	<	.
-	!	0	0	>	>	>	>	>	>	>	>	>	!	<	>	<	.
==	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
!=	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
<	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
>	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
<=	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
>=	!	<	<	<	<	>	>	>	>	>	>	>	!	<	>	<	.
??	!	<	<	<	<	<	<	<	<	<	<	<	!	<	>	<	.
=	!	<	<	<	<	<	<	<	<	<	<	<	!	<	!	<	.
(!	<	<	<	<	<	<	<	<	<	<	<	!	<	=	<	!
)	=	>	>	>	>	>	>	>	>	>	>	>	!	c	>	.	.
<i>t</i>	>	>	>	>	>	>	>	>	>	>	>	>	>	c	>	.	.
\$	<	<	<	<	<	<	<	<	<	<	<	<	<	!	!	<	.

Tabulka 1: Tabulka pro precedenční analýzu

Symbol	Název	Popis
<	PA_SHIFT	Shift
=	PA_PUSH	Push
>	PA_FOLD	Fold
.	PA_END	Successful end
!	PA_ERR	Error
x	PA_TOP	Shift if terminal is top, fold if non-terminal is top
0	PA_STOP	Fold if terminal after stop, shift if non-terminal after stop
c	PA_CALL	Parse function call

Tabulka 2: Legenda precedenční analýzy

3.3 Sémantická analýza

Sémantická analýza je implementována v modulu *semantics.c*, kde jsou na určitých místech prováděny kontroly, které zahrnují například ověření definice použitých funkcí a proměnných, počty proměnných a výrazů přiřazených do nich, shodu datových typů. Dále se kontroluje, zda nedochází k dělení nulou a zda návratové hodnoty funkcí odpovídají jejich hlavičkám.

Po úspěšném dokončení sémantické analýzy se přechází k tvorbě **abstraktně syntaktického stromu** (AST), který lze najít v *ast.c* a na základě kterého se nadále pracuje s generováním cílového kódu IFJcode23. V opačném případě při zjištění chyby končí program s odpovídající návratovou hodnotou a zároveň vypisuje na standardní chybový výstup informace a podrobnosti o daném problému.

3.3.1 Tabulka symbolů

Tabulky symbolů jsou implementovány jako **výškově vyvážené binární vyhledávací stromy** v modulu *symtable.c*. Každý uzel obsahuje identifikátor (klíč, díky kterému vyhledáváme uzly), data a 2 ukazatele na jeho podstromy.

Tabulky jsou uloženy ve vektoru a dělí na lokální a globální. Lokální pro lokální proměnné a globální pro funkce. Tabulky symbolů jsou implementovány jako rozptýlené tabulky.

3.4 Generování kódu

Generování cílového kódu IFJcode23 je poslední částí tohoto překladače, který lze najít v modulu *codegen.c*. Pro tvorbu finálního kódu se využívá abstraktně syntaktický strom na základě, kterého se tento výsledný kód vytváří.

3.5 Rozšíření

Vzhledem k omezenému časovému rozsahu projektu jsme se rozhodli soustředit pouze na základní implementaci a nezačleňovat do ní žádná rozšíření. Místo toho jsme se zaměřili na dokončení základní funkcionality, abychom mohli dodržet termíny a dosáhnout funkčního jádra projektu.

4 Práce v týmu

4.1 Organizace

Na projektu jsme snažili začít pracovat hned od začátku jeho zadání – tedy na začátku října. Celková komunikace probíhala především pomocí komunikační platformy **Discord**, kde jsme se domluvali na dalším postupu, a nebo na přednáškách, na kterých jsme se potkávali. Práci jsme si rozdělili na základě schopností a dovedností jednotlivých členů týmu. Na dílčích částech projektu pracovali především jednotlivci s pomocí tzv. *Pull request*, díky kterému jsme měli možnost poskytovat zpětnou vazbu na konkrétní části kódu a který nám umožnil verzovaný systém **Git**, přičemž jako úložiště našeho repozitáře jsme využili platformu **GitHub**. Právě Git nám umožnil pracovat na více úkolech projektu v tzv. větvích, které jsme po otestování a schválení začlenili do hlavní vývojové větve.

4.2 Rozdělení práce

Jméno člena týmu	Přidělená práce
Tomáš Daniel	vedení týmu, lexikální analýza, vv-BVS, sémantická analýza ...
Martin Slezák	...
Jakub Antonín Štigler	generování cílového kódu ...
Milan Vrbas	testování, dokumentace, prezentace

Tabulka 3: Rozdělení práce mezi jednotlivé členy týmu

5 Závěr

Cílem tohoto projektu bylo pochopit a následně si prakticky vyzkoušet metody probírané v předmětech IFJ a IAL, díky kterým jsme byli schopni implementovat překladač a jeho jednotlivé části. Bohužel jsme v době pokusného odevzdání projektu ještě nedosáhli fáze, kdy bychom ho mohli odevzdat a nechat otestovat. Většina členů týmu již měla zkušenost s prací na týmovém úkolu, což nám pomohlo s komunikací a celkovým postupem při plnění tohoto zadání úkolu.

Projekt byl vzhledem ke své časové náročnosti poměrně komplexní, což znamenalo, že vyžadoval podstatně více času a pozornosti než jsme původně předpokládali. Nicméně jsme se tomu dokázali postavit a úspěšně ho dokončili včas.